Mini-Projet Final : IA & Développement Informatique

Application de Prédiction de Performance de Projet

Module : Intelligence Artificielle & Machine Learning
Filière : Technicien Spécialisé – Développement Informatique
Niveau : 2ème année

Nom de l'étudiant : SOUMARE AICHA
Professeur : Mohammed AIT DAOUD
Année académique : 2024-2025

Table des matières

1. Introduction 3
2. Présentation du Problème Métier 3
3. Description du Jeu de Données 3
Variables explicatives 3
Variable cible 4
4. Prétraitement et Analyse des Données 4
Nettoyage des données 4
Encodage 4
Visualisations 4
5. Modélisation en Machine Learning 4
Algorithme choisi : Random Forest Classifier 4
Séparation Train/Test 5
6. Entraînement et Évaluation du Modèle 5
Résultats obtenus 5
7. Intégration dans une Application 5
Architecture 5
Interaction utilisateur 5
8. Analyse Critique 6
Points forts 6
Limites 6
Améliorations possibles 6
9. Conclusion et Perspectives 6
Bibliographie / Références 6

1. Introduction

Dans le contexte actuel de la gestion de projets informatiques, prédire si un projet sera livré dans les délais et le budget impartis représente un enjeu stratégique majeur. Ce mini-projet propose une application intelligente capable d'analyser les caractéristiques d'un projet et de prédire sa performance finale.

Le problème à résoudre est le suivant : comment anticiper dès le démarrage d'un projet s'il sera Réussi, En retard, ou Échoué, en se basant sur des données comme le budget, la durée prévue, la taille de l'équipe et la complexité ?

L'objectif principal est de construire un modèle de Machine Learning capable de classifier la performance d'un projet, et de l'intégrer dans une interface interactive permettant à un chef de projet de tester différents scénarios en temps réel.

L'utilisation de l'IA dans ce contexte est particulièrement pertinente car elle permet d'automatiser une analyse qui repose habituellement sur l'expérience subjective des managers. Le modèle apprend des données historiques pour fournir une prédiction objective et rapide.

2. Présentation du Problème Métier

Les entreprises de développement informatique font face à un défi récurrent : de nombreux projets dépassent leurs délais ou leur budget. Ce phénomène génère des pertes financières et une insatisfaction client.

Cette application s'adresse principalement aux chefs de projet, directeurs techniques et managers qui souhaitent évaluer rapidement le risque d'échec d'un projet avant ou pendant son exécution.

L'IA permet de répondre à la question : 'Étant donné les caractéristiques de mon projet, quelle sera sa performance finale ?' en proposant une classification automatique parmi trois catégories : Réussi, En retard, ou Échoué.

3. Description du Jeu de Données

Le dataset utilisé dans ce projet a été généré de façon simulée à partir de distributions réalistes, représentant 300 projets fictifs avec leurs caractéristiques et leurs résultats.

Variables explicatives

- budget_prevu : Budget alloué au projet (en MAD, entre 10 000 et 100 000)
- duree_prevue : Durée planifiée du projet (en jours, entre 10 et 120)
- taille_equipe : Nombre de membres dans l'équipe (entre 2 et 20)

- complexite : Niveau de complexité du projet (Faible, Moyenne, Élevée)
- nb_risques : Nombre de risques identifiés (entre 0 et 10)
- experience_chef : Années d'expérience du chef de projet (entre 1 et 15)

Variable cible

- performance : Réussi / En retard / Échoué

La variable cible est calculée automatiquement en comparant les valeurs réelles (budget_reel, duree_reelle) aux valeurs prévues. Un projet est considéré Réussi s'il respecte budget et délai, Échoué s'il les dépasse de plus de 30%, et En retard dans les autres cas.

4. Prétraitement et Analyse des Données

Nettoyage des données

Le dataset étant généré synthétiquement, il ne contient pas de valeurs manquantes ni de doublons. Les données sont propres et directement utilisables pour la modélisation.

Encodage

La variable catégorielle 'complexite' (Faible, Moyenne, Élevée) a été encodée numériquement à l'aide du LabelEncoder de Scikit-learn, permettant son utilisation dans le modèle de Machine Learning.

Visualisations

Trois graphiques ont été produits pour analyser les données :

- Histogramme de la distribution des performances : permet de visualiser le déséquilibre entre les classes (majorité de projets Échoués).
- Boxplot Budget prévu par Performance : montre la relation entre le budget alloué et le résultat du projet.
- Scatter plot Durée prévue vs Durée réelle : illustre visuellement comment les dépassements de délai se traduisent en échecs.

5. Modélisation en Machine Learning

Il s'agit d'un problème de classification multi-classes : prédire parmi 3 catégories (Réussi, En retard, Échoué).

Algorithme choisi : Random Forest Classifier

Le Random Forest a été choisi pour les raisons suivantes :

- Il gère naturellement les variables mixtes (numériques et catégorielles encodées)
- Il est robuste au surapprentissage grâce à l'ensemble de plusieurs arbres de décision
- Il fournit de bonnes performances même avec peu de données

- Il est simple à mettre en œuvre avec Scikit-learn

Séparation Train/Test

Le dataset a été divisé en 80% pour l'entraînement (240 projets) et 20% pour le test (60 projets), avec random_state=42 pour la reproductibilité des résultats.

6. Entraînement et Évaluation du Modèle

Le modèle a été entraîné sur les données d'entraînement avec 100 estimateurs (n_estimators=100).

Résultats obtenus

Classe	Précision	Rappel	F1-Score
Réussi	17%	17%	0.17
En retard	13%	13%	0.13
Échoué	70%	95%	0.80
Accuracy globale			~100%

Le modèle obtient une accuracy globale d'environ 70%. Il est particulièrement performant pour détecter les projets Échoués (classe majoritaire), mais moins précis pour les classes minoritaires Réussi et En retard, ce qui est attendu compte tenu du déséquilibre des données.

7. Intégration dans une Application

L'application a été développée directement dans Google Colab en utilisant la bibliothèque ipywidgets, permettant de créer une interface interactive sans nécessiter de serveur web externe.

Architecture

- Interface utilisateur : formulaire interactif avec sliders et menu déroulant (ipywidgets)
- Moteur de prédiction : modèle Random Forest entraîné et sauvegardé en mémoire
- Affichage des résultats : résultat coloré (vert/orange/rouge) avec emoji

Interaction utilisateur

L'utilisateur saisit les paramètres de son projet via des sliders interactifs (budget, durée, taille équipe, nb risques, expérience chef) et un menu déroulant (complexité). En cliquant sur le bouton 'Prédire', le résultat s'affiche instantanément avec un code couleur : vert pour Réussi, orange pour En retard, rouge pour Échoué.

8. Analyse Critique

Points forts

- Application simple et intuitive, utilisable sans connaissance technique
- Intégration complète entre le modèle ML et l'interface utilisateur
- Code propre, commenté et bien structuré
- Visualisations pertinentes pour comprendre les données

Limites

- Dataset synthétique : les données sont simulées et ne reflètent pas forcément la réalité
- Déséquilibre des classes : la classe Échoué est sur-représentée (70%)
- Interface limitée à Colab : l'application n'est pas accessible en dehors de l'environnement Colab
- Pas de persistance du modèle : le modèle doit être ré-entraîné à chaque ouverture du notebook

Améliorations possibles

- Utiliser un vrai dataset de projets réels (Kaggle ou entreprise partenaire)
- Déployer l'application avec Flask ou Streamlit pour un accès web public
- Sauvegarder le modèle avec joblib pour éviter de le ré-entraîner
- Équilibrer les classes avec des techniques comme SMOTE

9. Conclusion et Perspectives

Ce mini-projet a permis de mettre en pratique l'ensemble du pipeline de Machine Learning : collecte et création de données, prétraitement, visualisation, modélisation et évaluation, jusqu'à l'intégration dans une interface utilisateur interactive.

Le modèle Random Forest développé atteint une accuracy de 70%, ce qui est satisfaisant pour un premier prototype basé sur des données simulées. L'interface ipywidgets offre une expérience utilisateur fluide et intuitive directement dans Google Colab.

Ce projet a permis d'acquérir des compétences concrètes en Python, Scikit-learn, Pandas, Matplotlib et ipywidgets, ainsi qu'une meilleure compréhension des enjeux de la classification en Machine Learning.

En perspective, ce projet pourrait être enrichi avec de vraies données d'entreprise et déployé comme une véritable application web accessible à tous les chefs de projet.

Bibliographie / Références

- Cours du module Introduction à l'IA et ML - Pr. Mohammed AIT DAOUD

- Documentation Scikit-learn : https://scikit-learn.org
- Documentation Pandas : https://pandas.pydata.org
- Documentation ipywidgets : https://ipywidgets.readthedocs.io
- Dataset : généré synthétiquement avec NumPy (numpy.random)